Notas de Clase: Análisis de Regresión y Análisis Multivariante

Esperanza condicional, MCO, Componentes Principales, Análisis Factorial y Clustering

Benjamín Oliva[1]

Draft Diciembre 2025

[1] benjov@ciencias.unam.mx y https://github.com/benjov

Documento siempre proceso de mejora.
Comentarios siempre serán bienvenidos...
Este documento servirá para el curso de Análisis Multivariante de la Licenciatura en Economía.

Índice general

1. Regresión Lineal **3**
1.1. Introducción y motivación 3
1.2. El concepto de regresión entre dos variables 3
1.3. Modelo de regresión lineal 9
1.3.1. Supuestos del modelo de regresión lineal 9
1.3.2. Estimación de los parámetros del modelo lineal bivariado 12
1.4. Estimación de parámetros por mínimos cuadrados 15
1.5. Modelos no lineales 18
1.5.1. Regresión exponencial 19
1.5.2. Regresión logarítmica 20
1.5.3. Funciones logísticas 20
1.6. Modelo de regresión lineal múltiple 23

2. Aprendizaje no supervisado - Técnicas de Clúster **35**
2.1. Análisis de Componentes Principales 35
2.2. Análisis Factorial 37
2.3. Clúster 37
2.3.1. K-Means Clustering 39
2.3.2. Clustering Jerárquico 40
2.3.3. Método de K-means con datos de epidemiológicos. . . . 42
2.3.4. Agrupamiento de datos de series temporales 43
2.3.5. Método de K-means para series de tiempo. 49

Bibliografía **51**

A. Algunos teoremas y resultados relevantes **53**
A.1. Convergencia 53

Índice de figuras

1.1. Relación entre Latitud y Velocidad del Viento 4
1.2. Relación entre Latitud y Temperatura 4
1.3. Relación entre Latitud y Nubocidad 5
1.4. Relación entre Latitud y Humedad 5
1.5. Supuestos del modelo lineal (Retomado de Larsen (2012, p 545)Larsen y Marx 2012), donde se muestra una notación con las siguientes equivalencias $f_{Y|x}(y) = f(Y|x)$ y $y = \mu_{Y|x} = \mathbb{E}[Y|x]$ 10
1.6. Ilustración del error de estimación, retomado de Greene (2012, pp. 40) Greene 2012 16
1.7. Funciones exponenciales, Retomado de Larsen y Marx (2012, p. 532) Larsen y Marx 2012 20
1.8. Funciones logarítmicas, Retomado de Larsen y Marx (2012, p. 536) Larsen y Marx 2012 21
1.9. Funciones logísticas, Retomado de Larsen y Marx (2012, p. 540) Larsen y Marx 2012 22
1.10. Ilustración de la poroyección de y en x_1 y x_2 y el significado del error e, retomado de Greene (2012, pp. 20) Greene 2012 . . 24
1.11. Ilustración del hiperplano generado dee regresar X_1 y X_2 en Y, retomado de Hastie, Tibshirani y Friedman (2009, pp. 45) Hastie, Tibshirani y Friedman 2017 24
1.12. Ilustración de la poroyección de y en x_1 y x_2 y el significado del error e, retomado de Hastie, Tibshirani y Friedman (2009, pp. 46) Hastie, Tibshirani y Friedman 2017 25
1.13. Gráfica de Precios y Cantidades, y su recta de regresión 34

2.1. US Arrest Hierarchical Clustering, retomado de Chang (2020, p 216) Chang 2020 39

2.2. Agglomerative Clustering Algorithm and Dendrogram, retomado de Chang (2020, p 219) Chang 2020 42

Índice de cuadros

1.1. Tabla de Precios y Cantidades 33
1.2. Regresión resultados 34

Introducción, motivación y alcance del documento

Este documento servirá como guía para impartir el curso de Análisis Multivariante en la Licenciatura en Economía del Tec.

En el curso queremos discutir los documentos de la bibliografía como: Chang 2020, Greene 2012, Hair et al. 2006, Hastie, Tibshirani y Friedman 2017 y Larsen y Marx 2012.

Conocimientos previos

Cálculo Diferencial e Integral y Álgebra Lineal.

Recursos en línea y otros materiales

Materiales recomendados durante el curso y autoaprendizaje.

Perspectiva histórica[1]

[1] Retomado de Larsen y Marx 2012, Cap. 1

1

Regresión Lineal

1.1. Introducción y motivación

En esta sección analizaremos el concepto de regresión lineal. El cual está basado en la observación cotidiana de cómo es la relación entre dos o más variables, una dependiente, y, y otras independientes (o dadas), x, dado que hemos obtenido una muestra aleatoria. Por ejemplo, ¿qué determina el cáncer pulmonar en las personas? Algunas respuestas son: fumar, dieta, contaminación, condiciones genéticas, etc.

Otros ejemplos son, si la latitud explica algunas condiciones climáticas. Las figuras 1.1, 1.2, 1.3, 1.4 muestran la relación geometrica entre la latitud y diversas variables del clima para una muestra de 500 ciudades en la fecha que se señala.

1.2. El concepto de regresión entre dos variables

Definición 1.1 *Sea $f(Y|x)$ la función de densidad de probabilidad de una variable aleatoria Y dado un valor de $X = x$, y sea $\mathbb{E}[Y|x]$ el valor esperado asociado con la función $f(Y|x)$. La función:*

$$\mu_{Y|x} = \mathbb{E}[Y|x]$$

se denomina como la curva de regresión de Y en $X = x$. De forma similar podemos definir la curva de regresión de X en $Y = y$.

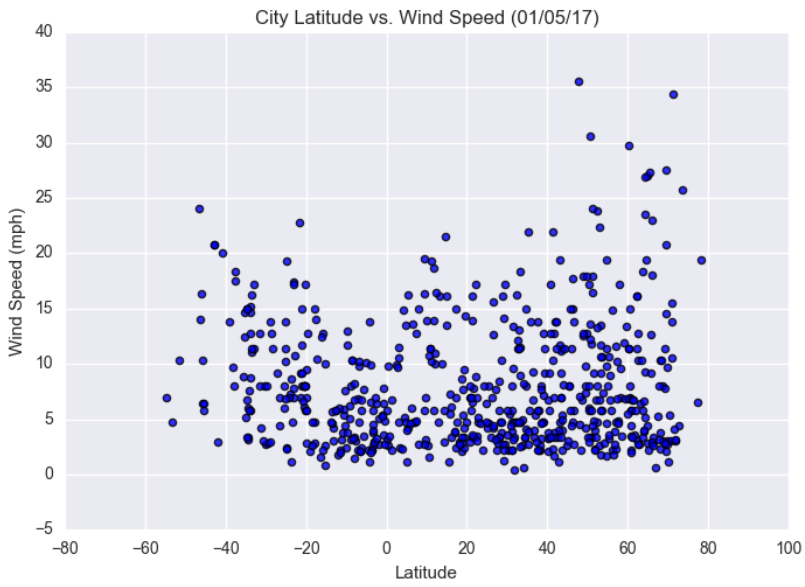

Figura 1.1: Relación entre Latitud y Velocidad del Viento

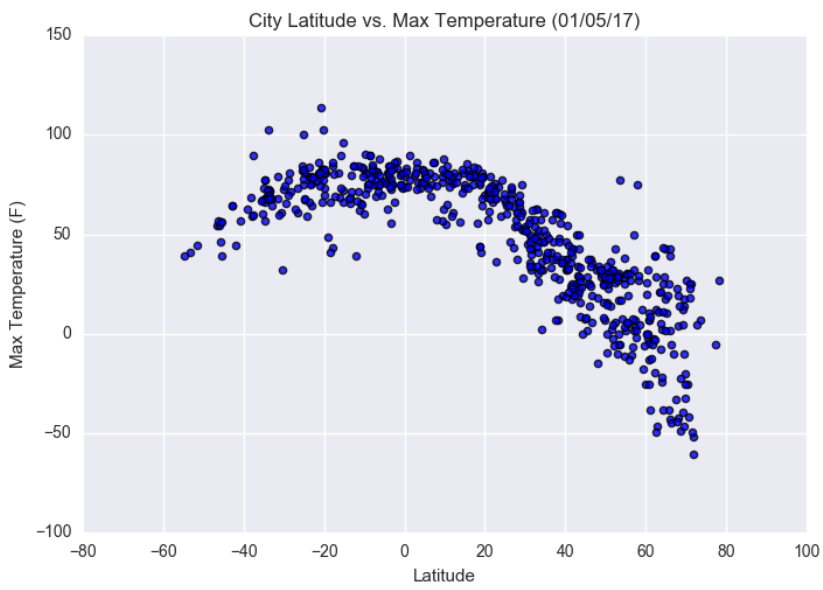

Figura 1.2: Relación entre Latitud y Temperatura

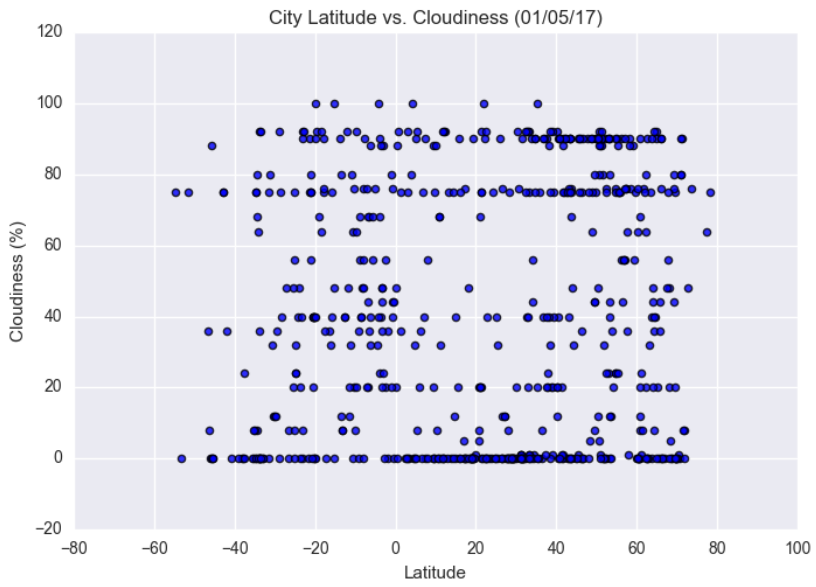

Figura 1.3: Relación entre Latitud y Nubocidad

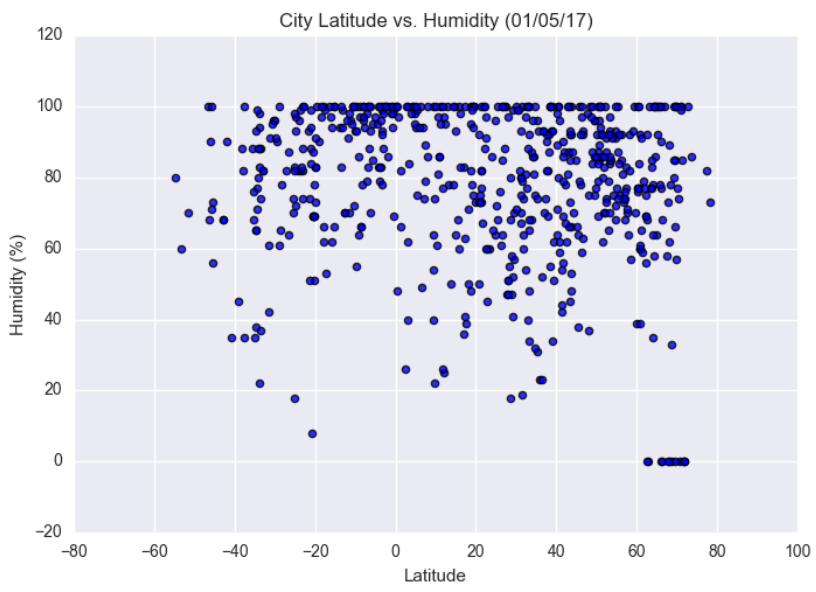

Figura 1.4: Relación entre Latitud y Humedad

Ejemplo. Supongamos una función dada por:

$$f(Y|x) = \begin{cases} \frac{x+y}{x+\frac{1}{2}} & \text{para } 0 \leq y \leq 1, 0 \leq x \leq 1 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Determinemos la función de regresión de Y en $X = x$. Para ello primero determinemos si $f(Y|x)$ es una función de densidad de probabilidad condicional:

$$\begin{aligned} \int_D f(Y|x)dy &= \int_0^1 \frac{x+y}{x+\frac{1}{2}}dy = \int_0^1 \frac{x}{x+\frac{1}{2}}dy + \int_0^1 \frac{y}{x+\frac{1}{2}}dy \\ &= \left.\frac{xy}{x+\frac{1}{2}}\right|_0^1 + \left.\frac{y^2/2}{x+\frac{1}{2}}\right|_0^1 = \frac{x}{x+\frac{1}{2}} + \frac{\frac{1}{2}}{x+\frac{1}{2}} \\ &= \frac{x+\frac{1}{2}}{x+\frac{1}{2}} = 1 \end{aligned}$$

Por lo tanto, observamos que $f(Y|x)$ es una función de densidad de probabilidad. Ahora determinemos $\mu_{Y|x}$:

$$\begin{aligned} \mu_{Y|x} &= \mathbb{E}[Y|x] = \int_0^1 y\frac{x+y}{x+\frac{1}{2}}dy = \int_0^1 \frac{xy+y^2}{x+\frac{1}{2}}dy = \left.\frac{\frac{xy^2}{2}+\frac{y^3}{3}}{x+\frac{1}{2}}\right|_0^1 \\ &= \frac{\frac{x}{2}+\frac{1}{3}}{x+\frac{1}{2}} = \frac{\frac{3x}{2}+1}{3x+\frac{3}{2}} = \frac{3x+2}{6x+3} \end{aligned}$$

Podemos platear una definición más amplia:

Definición 1.2 *Sea $f(x,y)$ una función de densidad conjunta de las variables aleatorias X y Y, la función de regresión consiste en determinar la densidad condicional de Y dado $X = x$, la cual resulta de evaluar la integral:*

$$\mu_{Y|x} = \mathbb{E}[Y|x] = \int_D y \cdot f(Y|x)dy$$

El resultado de la integral es denominado como ecuación de regresión de Y en X. De forma similar, la regresión de X en Y estará dada por:

$$\mu_{X|y} = \mathbb{E}[X|y] = \int_D x \cdot f(X|y)dx$$

Donde las funciones de densidad condicional resultan de:

$$\begin{aligned} f(Y|x) &= \frac{f(x,y)}{g(x)} \\ f(X|y) &= \frac{f(x,y)}{g(y)} \end{aligned}$$

Y las funciones marginales son resultado de:

$$\begin{aligned} g(x) &= \int_{D_y} f(x,y)dy \\ g(y) &= \int_{D_x} f(x,y)dx \end{aligned}$$

Ejemplo. Dadas dos variables aleatorias X y Y con función de densidad conjuntandada por:

$$f(x,y) = \begin{cases} x \cdot e^{-x(1+y)} & \text{para } x > 0, y > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Determinemos la ecuación de regresión de Y en X. Para ello requerimos de:

$$\begin{aligned} g(x) &= \int_{D_y} f(x,y)dy = \int_{D_y} x \cdot e^{-x(1+y)}dy = -e^{-x(1+y)}\Big|_0^\infty \\ &= \begin{cases} e^{-x} & \text{para } x > 0 \\ 0 & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

De esta forma podemos determinar la función de densidad condicional como:

$$f(Y|x) = \frac{f(x,y)}{g(x)} = \frac{x \cdot e^{-x(1+y)}}{e^{-x}} = \begin{cases} x \cdot e^{-xy} & \text{para } y > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Podemos observar que es una función de densidad ya que:

$$\int_{D_y} f(Y|x)dy = \int_0^\infty x \cdot e^{-xy}dy = e^{-xy}\Big|_0^\infty = 1$$

Finalmente, la ecuación de regresión de Y en X estará dada por:

$$\begin{aligned}
\mu_{Y|x} &= \mathbb{E}[Y|x] = \int_{D_y} y \cdot f(Y|x)dy = \int_0^\infty y \cdot x \cdot e^{-xy}dy \\
&= -y \cdot e^{-xy}\Big|_0^\infty + \int_0^\infty e^{-xy}dy = -y \cdot e^{-xy}\Big|_0^\infty - \frac{1}{x}e^{-xy}\Big|_0^\infty \\
&= \begin{cases} \frac{1}{x} & \text{para } x > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}
\end{aligned}$$

Ejemplo. Supongamos una función de densidad conjunta de X_1, X_2, X_3 variables aleatorias dada por:

$$f(x_1, x_2, x_3) = \begin{cases} (x_1 + x_2)e^{-x_3} & \text{para } 1 > x_1 > 0, 1 > x_2 > 0, x_3 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Determinemos la ecuación de regresión de X_2 en X_1 y X_3. Para ello requerimos de la función de densidad marginal dada por:

$$\begin{aligned}
g(x_1, x_3) &= \int_{D_{x_2}} f(x_1, x_2, x_3)dx_2 = \int_0^1 (x_1 + x_2)e^{-x_3}dx_2 \\
&= \left(x_1x_2 + \frac{x_2^2}{2}\right)e^{-x_3}\Big|_0^1 \\
&= \begin{cases} \left(x_1 + \frac{1}{2}\right)e^{-x_3} & \text{para } 1 > x_1 > 0, x_3 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}
\end{aligned}$$

Determinemos entonces la función de densidad condicional, la cual estará dada por:

$$\begin{aligned}
f(X_2|x_1, X_3) &= \frac{f(x_1, x_2, x_3)}{g(x_1, x_3)} = \frac{(x_1 + x_2)e^{-x_3}}{\left(x_1 + \frac{1}{2}\right)e^{-x_3}} \\
&= \begin{cases} \frac{x_1+x_2}{x_1+\frac{1}{2}} & \text{para } 1 > x_1 > 0, 1 > x_2 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}
\end{aligned}$$

Entoncees, la ecuación de regresión estará dada por:

$$\begin{aligned}
\mu_{X_2|x_1,x_3} &= \int_{D_{x_2}} x_2 \cdot f(X_2|x_1, X_3)dx_2 = \int_0^1 x_2\frac{x_1 + x_2}{x_1 + \frac{1}{2}}dx_2 = \frac{\frac{x_1x_2^2}{2} + \frac{x_2^3}{3}}{x_1 + \frac{1}{2}}\Bigg|_0^1 \\
&= \frac{\frac{x_1}{2} + \frac{1}{3}}{x_1 + \frac{1}{2}} = \begin{cases} \frac{x_1+\frac{2}{3}}{2x_1+1} & \text{para } 1 > x_1 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}
\end{aligned}$$

1.3. Modelo de regresión lineal

1.3.1. Supuestos del modelo de regresión lineal

Un caso especial es el de la regresión lineal. Lo que hasta ahora hemos visto es el caso general en el que $\mu_{Y|x} = \mathbb{E}[Y|x]$, el cual modificaremos bajo los siguientes supuestos – **Supuestos del Modelo Lineal**:

1. **Normalidad**. $f(Y|x)$ es una función de densidad de probabilidad normal $\forall x$

2. **Homocedásticidad**. La desviación estánndar, σ, asociada con $f(Y|x)$ es la misma $\forall x$

3. **Linealidad**. Las medias de todas las distribuciones condicionales son una combinación lineal dada por:

$$\mu_{Y|x} = \mathbb{E}[Y|x] = \beta_0 + \beta_1 x$$

   Donde β_0 y β_1 son parámetros por determinar, como veremos más adelante

4. Todas las distribuciones condicionales representan variables aleatorias independientes como se ilustra en la Figura 1.5.

Ahora enunciaremos un teorema relvante para el caso del modelo lineal.

Teorema 1.1 *Sean Y y X dos variables aleatorias que cumplen con los supuestos del modelo lineal. Si la regresión de Y en X es linneal, entonces:*

$$\mu_{Y|x} = \mu_Y + \rho\frac{\sigma_Y}{\sigma_X}(x - \mu_X)$$

Si la regresión de X en Y es lineal, entonces:

$$\mu_{X|y} = \mu_X + \rho\frac{\sigma_X}{\sigma_Y}(y - \mu_Y)$$

Para demostrar el teorema anterior partamos de recordar que la media condicional estará dada por:

$$\mu_{Y|x} = \int_{D_y} y \cdot f(Y|x)dy = \beta_0 + \beta_1 x \tag{1.1}$$

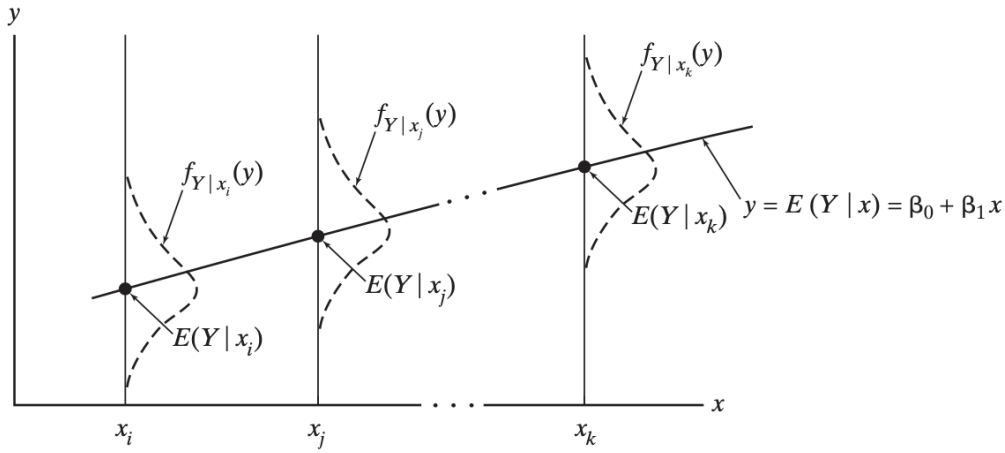

Figura 1.5: Supuestos del modelo lineal (Retomado de Larsen (2012, p 545)Larsen y Marx 2012), donde se muestra una notación con las siguientes equivalencias $f_{Y|x}(y) = f(Y|x)$ y $y = \mu_{Y|x} = \mathbb{E}[Y|x]$

Multiplicando cada uno de los lados de la última parte de la ecuación (1.1) por $g(x)$, la función de densidad de probabilidad marginal, e integrando ambos lados tenemos lo siguiente:

$$\begin{aligned}
\int_{D_x}\int_{D_y} y \cdot f(Y|x)g(x)dydx &= \beta_0 \int_{D_x} g(x)dx + \beta_1 \int_{D_x} x \cdot g(x)dx \\
\iff \int_{D_x}\int_{D_y} y \cdot f(x,y)dydx &= \beta_0 + \beta_1\mu_X \\
\iff \int_{D_y}\int_{D_x} y \cdot f(x,y)dxdy &= \beta_0 + \beta_1\mu_X \\
\iff \int_{D_y} y \cdot g(y)dy &= \beta_0 + \beta_1\mu_X \\
\iff \mu_Y &= \beta_0 + \beta_1\mu_X \qquad (1.2)
\end{aligned}$$

Retomando la ecuación (1.1) y multiplicando por un factor dado por

$x \cdot g(x)$ e integrando, tenemos:

$$\begin{aligned}
\int_{D_x}\int_{D_y} y \cdot f(Y|x) \cdot x \cdot g(x) dy dx &= \beta_0 \int_{D_x} x \cdot g(x) dx + \beta_1 \int_{D_x} x^2 \cdot g(x) dx \\
\iff \int_{D_x}\int_{D_y} x \cdot y \cdot f(x,y) dy dx &= \beta_0 \mu_X + \beta_1 \mathbb{E}[X^2] \\
\iff \mathbb{E}[X \cdot Y] &= \beta_0 \mu_X + \beta_1 \mathbb{E}[X^2] \qquad (1.3)
\end{aligned}$$

Aquí recordamos un par de resultados que conocemos:

$$Cov(X,Y) = \mathbb{E}[X \cdot Y] - \mathbb{E}[X]\mathbb{E}[Y] = \sigma_{XY} = \mathbb{E}[X \cdot Y] - \mu_X \mu_Y$$

$$\mathbb{E}[X \cdot Y] = \sigma_{XY} + \mu_X \mu_Y$$

$$Var(X) = \mathbb{E}[X^2] - \mu_X^2 = \sigma_X^2$$

$$\mathbb{E}[X^2] = \sigma_X^2 + \mu_X^2$$

Retomando las ecuaciones (1.2) y (1.3) y los resultados mostrados tenemos que resolver el siguiente sistema de ecuaciones:

$$\begin{aligned}
\mu_Y &= \beta_0 + \beta_1 \mu_X \\
\sigma_{XY} + \mu_X \mu_Y &= \beta_0 \mu_X + \beta_1 (\sigma_X^2 + \mu_X^2)
\end{aligned}$$

De la primera despejamos:

$$\beta_0 = \mu_Y - \beta_1 \mu_X$$

Sustituimos en la segunda para encontrar:

$$\begin{aligned}
\sigma_{XY} + \mu_X \mu_Y &= (\mu_Y - \beta_1 \mu_X)\mu_X + \beta_1 (\sigma_X^2 + \mu_X^2) \\
&= \mu_X \mu_Y - \beta_1 \mu_X^2 + \beta_1 \sigma_X^2 + \beta_1 \mu_X^2 \\
\sigma_{XY} &= \beta_1 \sigma_X^2
\end{aligned}$$

De donde:

$$\beta_1 = \frac{\sigma_{XY}}{\sigma_X^2} = \frac{\sigma_X \sigma_Y}{\sigma_X \sigma_Y} \frac{\sigma_{XY}}{\sigma_X^2} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} \frac{\sigma_X \sigma_Y}{\sigma_X^2} = \rho \frac{\sigma_Y}{\sigma_X}$$

Y:

$$\beta_0 = \mu_Y - \rho\frac{\sigma_Y}{\sigma_X}\mu_X$$

Sustituyendo en la ecuación de regresión:

$$\begin{aligned}
\mu_{Y|x} &= \beta_0 + \beta_1 x \\
&= \mu_Y - \rho\frac{\sigma_Y}{\sigma_X}\mu_X + \rho\frac{\sigma_Y}{\sigma_X}x \\
&= \mu_Y + \rho\frac{\sigma_Y}{\sigma_X}(x - \mu_X)
\end{aligned}$$

Con lo cual hemos demotrado la primera parte del teorema. La segunda parte se demustra de forma simlar.

1.3.2. Estimación de los parámetros del modelo lineal bivariado

Antes de plantear el proceso de estimación respondamos ¿cuáles son los parámetros $\boldsymbol{\theta'} = (\theta_1, \theta_2, \ldots, \theta_K)'$ del modelo lineal dado por $\mathbb{E}[Y|x] = \beta_0 + \beta_1 x$? Así, $\boldsymbol{\theta'} = (\beta_0, \beta_1, \sigma^2)'$. Dado que asumimos que Y tienen una distribución de probabilidad, en este caso normal, podemos determinar los parámetros por medio del uso de un procedimiento de máxima verosimilitud.

Sean $\{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$ un conjunto de datos que satisfacen los supuestos del modelo lineal, entonces podemos establecer la siguiente transformación Z y la función de verosimilitud:

$$Z_i = \frac{y_i - \mathbb{E}[Y|x_i]}{\sigma}$$

$$\begin{aligned}
L &= \Pi_{i=1}^n f(Y_i|x_i) = \Pi_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}Z_i^2} = \Pi_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y_i - \mathbb{E}[Y|x_i]}{\sigma}\right)^2} \\
&= \Pi_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y_i - \beta_0 - \beta_1 x}{\sigma}\right)^2} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{1}{2}\sum_{i=1}^n \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2} \\
&= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2}\sum_{i=1}^n \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2} \qquad (1.4)
\end{aligned}$$

Tomando el logaritmo de la ecuación (1.4) tenemos:

$$
\begin{aligned}
ln(L) &= -\frac{n}{2}ln(2\pi) - \frac{n}{2}ln(\sigma^2) - \frac{1}{2}\sum_{i=1}^{n}\left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2 && (1.5)\\
-2ln(L) &= n \cdot ln(2\pi) + n \cdot ln(\sigma^2) + \sum_{i=1}^{n}\left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2 && (1.6)
\end{aligned}
$$

Ambas ecuaciones (1.5) y (1.6) son equivalentes. La ecuación (1.6) es conocida por ser la expresión de la forma log-normal o una expresión de Chi cuadrado. De la ecuación (1.5) obtendremos el siguiente vector gradiente:

$$
\frac{\partial ln(L)}{\partial \boldsymbol{\theta}} = \begin{bmatrix} \frac{\partial ln(L)}{\partial \beta_0} \\ \frac{\partial ln(L)}{\partial \beta_1} \\ \frac{\partial ln(L)}{\partial \sigma^2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) \\ \frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)x_i \\ -\frac{n}{2\sigma^2} + \frac{1}{(\sigma^2)^2}\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)^2 \end{bmatrix}
$$

Así, podemos obtener las siguientes expresiones para los parámetros:

$$
\begin{aligned}
\frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) &= 0\\
\sum_{i=1}^{n} y_i - \sum_{i=1}^{n}\beta_0 - \sum_{i=1}^{n}\beta_1 x_i &= 0\\
\sum_{i=1}^{n} y_i - n\beta_0 - \sum_{i=1}^{n}\beta_1 x_i &= 0\\
\beta_0 &= \frac{\sum_{i=1}^{n} y_i - \beta_1 \sum_{i=1}^{n} x_i}{n} && (1.7)
\end{aligned}
$$

Para la segunda ecuación del gradiente y utilizando 1.7 tenemos:

$$\begin{aligned}
\frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i-\beta_0-\beta_1x_i)x_i &= 0\\
\sum_{i=1}^{n}y_ix_i-\sum_{i=1}^{n}\beta_0x_i-\sum_{i=1}^{n}\beta_1x_i^2 &= 0\\
\sum_{i=1}^{n}y_ix_i-\beta_0\sum_{i=1}^{n}x_i-\beta_1\sum_{i=1}^{n}x_i^2 &= 0\\
\sum_{i=1}^{n}y_ix_i-\left(\frac{\sum_{i=1}^{n}y_i-\beta_1\sum_{i=1}^{n}x_i}{n}\right)\sum_{i=1}^{n}x_i-\beta_1\sum_{i=1}^{n}x_i^2 &= 0\\
n\sum_{i=1}^{n}y_ix_i-\sum_{i=1}^{n}y_i\sum_{i=1}^{n}x_i+\beta_1\sum_{i=1}^{n}x_i\sum_{i=1}^{n}x_i-\beta_1n\sum_{i=1}^{n}x_i^2 &= 0\\
-\sum_{i=1}^{n}y_i\sum_{i=1}^{n}x_i+n\sum_{i=1}^{n}y_ix_i+\beta_1\left(\left(\sum_{i=1}^{n}x_i\right)^2-n\sum_{i=1}^{n}x_i^2\right) &= 0 \quad (1.8)
\end{aligned}$$

Utilizando las ecuaciones (1.7) y (1.8) llegamos a las siguientes soluciones para los estimadores de los parámetros:

$$\hat{\beta}_1=\frac{n\sum_{i=1}^{n}y_ix_i-\sum_{i=1}^{n}y_i\sum_{i=1}^{n}x_i}{n\sum_{i=1}^{n}x_i^2-\left(\sum_{i=1}^{n}x_i\right)^2} \tag{1.9}$$

$$\hat{\beta}_0=\overline{Y}-\hat{\beta}_1\overline{X} \tag{1.10}$$

Finalmente:

$$-\frac{n}{2\sigma^2}+\frac{1}{(\sigma^2)^2}\sum_{i=1}^{n}(y_i-\beta_0-\beta_1x_i)^2=0$$

De donde obtenemos que:

$$\hat{\sigma}^2=\frac{\sum_{i=1}^{n}(y_i-\hat{\beta}_0-\hat{\beta}_1x_i)^2}{n} \tag{1.11}$$

Estos estimadores de las ecuaciones (1.10), (1.9) y (1.11) requieren de verificar sus propiedades de sesgo, consistencia y eficiencia. No obstante, lo dejaremos para más adelante en el caso de regresión múltiple.

1.4. Estimación de parámetros por mínimos cuadrados

Hasta el momento hemos discutido el problema de regresión, lineal o no lineal, partiendo de que conocemos la función de densidad de probabilidad de las variables aleatorias involucradas. En la realidad no siempre es factible conocerlas, y por lo tanto tampoco es factible conocer la función de densidad conjunta de dichas variables.

Pero nuestro problema sigue siendo el mismo, queremos determinar los parámetros β_0 y β_1 que pueden ayudarnos a ajustar una curva de regresión. En esta sección discutiremos el método de mínimso cuadrados ordinarios, el cual fue implementado por Adrian Legendre.

Una motivación del método es geométrica. La cual considera la relación entre dos o más variables aleatorias, digamos que observamos puntos en el plano cartesiano: $\{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$ y supongamos una constante m que determina el grado del polinomio:

$$\hat{y}_i = p(x_i) = \hat{\beta}_0 + \sum_{j=1}^{m} \hat{\beta}_j x_i^j$$

Para cualquier grado del polinomio podemos definir a los residuales para cualquier punto $i = 1, 2, \ldots, n$ en el plano como:

$$\begin{aligned} e_i &= y_i - \hat{y}_i \\ &= y_i - \hat{\beta}_0 - \sum_{j=1}^{m} \hat{\beta}_j x_i^j \end{aligned}$$

Sin pérdida de generalidad, puesto que el siguiente plateamiento es válido para cualquier grado de polinomio, diremos que:

$$e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

En la Figura 1.6 ilustramos el concepto de error.

El método de mínimos cuadrados ordinarios consiste en resolver un problema de minimización de la una función que depende de los residuales que hemos definido. El la función introducimos los residuales al cuadrado con el objeto de aproximar el problema como uno de minimización de distancias

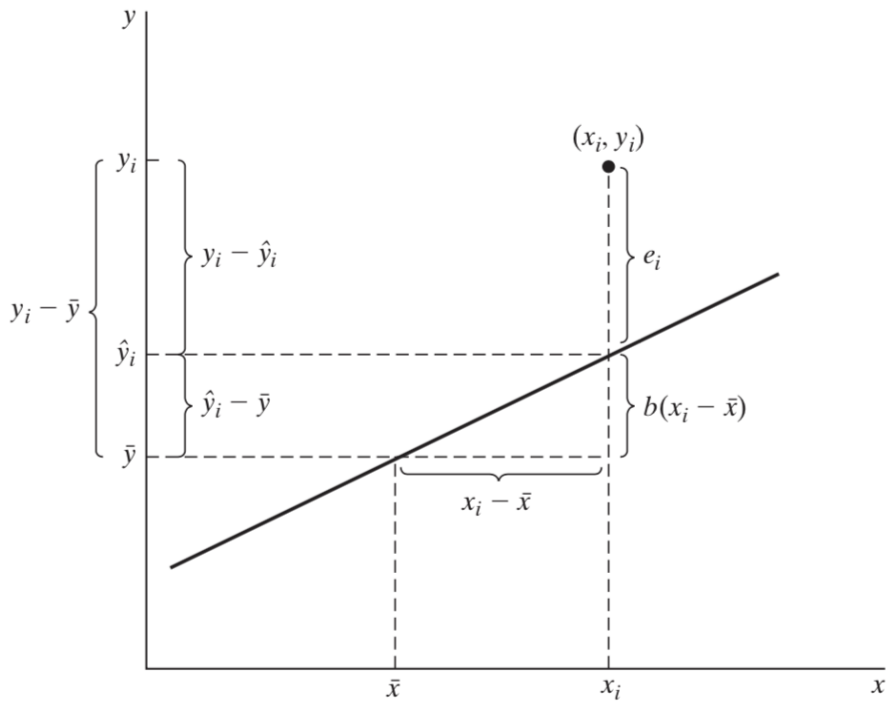

Figura 1.6: Ilustración del error de estimación, retomado de Greene (2012, pp. 40) Greene 2012

entre la coordenada y_i y la coordenada x_i de forma conjunta para todos los elementos en la muestra, $i = 1, 2, \ldots, n$.

Así, partimos del siguiente planteamiento en el cual desconocemos los parámetros β_0 y β_1:

$$\begin{aligned} S(\beta_0, \beta_1) &= \sum_{i=1}^{n} e_i^2 \\ &= \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2 \end{aligned}$$

Para mimimizar la función anterior requerimos de las condciones de primer orden dadas como:

$$\begin{aligned} \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} &= -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) \\ \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} &= -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) x_i \end{aligned}$$

A estas expresiones se les suele conocer como ecuaciones normales. Si igualamos a cero y reolvemos para encontrar los valores que minimizan las distancias tendremos que:

$$\begin{aligned} -2 \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0 \\ -2 \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i &= 0 \end{aligned}$$

De donde podemos encontrar que:

$$\begin{aligned} \sum_{i=1}^{n} y_i &= n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^{n} x_i \\ \sum_{i=1}^{n} y_i x_i &= \hat{\beta}_0 \sum_{i=1}^{n} x_i + \hat{\beta}_1 \sum_{i=1}^{n} x_i^2 \end{aligned}$$

Continuando:

$$\begin{aligned}
\hat{\beta}_0 &= \frac{\sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i}{n} \\
&= \frac{\sum_{i=1}^n y_i}{n} - \frac{\hat{\beta}_1 \sum_{i=1}^n x_i}{n} \\
&= \overline{Y} - \hat{\beta}_1 \overline{X}
\end{aligned}$$

$$\begin{aligned}
\sum_{i=1}^n y_i x_i &= \left(\frac{\sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i}{n} \right) \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
n \cdot \sum_{i=1}^n y_i x_i &= \sum_{i=1}^n y_i \sum_{i=1}^n x_i - \hat{\beta}_1 \left(\sum_{i=1}^n x_i \right)^2 + \hat{\beta}_1 n \cdot \sum_{i=1}^n x_i^2 \\
\hat{\beta}_1 &= \frac{n \cdot \sum_{i=1}^n y_i x_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{n \cdot \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i\right)^2}
\end{aligned}$$

Por lo tanto, las soluciones serían:

$$\begin{aligned}
\hat{\beta}_0 &= \overline{Y} - \hat{\beta}_1 \overline{X} \\
\hat{\beta}_1 &= \frac{n \cdot \sum_{i=1}^n y_i x_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{n \cdot \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i\right)^2}
\end{aligned}$$

Estas soluciones son las mismas que obtuvimos por el procedimiento de Máxima Verosimilitud.

1.5. Modelos no lineales

¿Qué pasa cuando la relación observada entre las variables no es lineal? Casi siempre pasa eso. A continuación discutiremos tres casos de ecuaciones que nos ayudaran a describir una relación no lineal mediante una transformación que hace la relaciones lineales. Cada uno responde a condiciones o características que la experiencia del investigador tiene que solventar.

Cada una de las ecuaciones se distingue por la tasa de cambio de la variable y en relación a los cambios de la variable x. Partamos de que la forma más simple de una relación lineal está dada por la ecuación (1.12). Note que hemos eliminado los subíndices para indicar que la ecuacion se

cumple para cada uno de los elementos en la muestra, $i = 1, 2, \ldots, n$. Sin pérdida de generalidad digamos que en lugar de β_0 y β_1 empleamos a y b como constantes, y asumimos $\mu_{Y|x} = y$, como una forma de ilustrar cada uno de los fenómenos que discutimos a continuación.

$$y = a + bx \tag{1.12}$$

Esta ecuación (1.12) tiene la característica de que tiene una tasa de variación constante para y en relación a x, de esta forma:

$$\frac{dy}{dx} = b \Longleftrightarrow dy = bdx \Longleftrightarrow \int dy = \int bdx \Longleftrightarrow y = a + bx$$

Los siguientes modelos no lineales tienen una motivación similar, dependen de la forma en que se asuma la variación de y en función de la variación de x.

1.5.1. Regresión exponencial

Supongamos que y depende de x y que los cambios en y darivados de x son proporcionales a y, es decir:

$$\frac{dy}{dx} = by$$

Donde b es una constante. De esta forma podemos encontar que:

$$\frac{dy}{dx} = by \Longleftrightarrow \frac{dy}{y} = bdx \Longleftrightarrow \int \frac{dy}{y} = \int bdx \Longleftrightarrow ln(y) = a + bx$$

De esta forma, tenemos que:

$$y = e^{bx}e^{a} \Longleftrightarrow y = ke^{bx}$$

Por lo tanto, cuando estimamos una relación: $ln(y) = a + bx$ estamos asumiendo que existe la sigueinte relación: $\frac{dy}{dx} = by$. A este tipo de ecuaciones se les conoce como log-lineales. En la Figura 1.7 se ilustra la relación log-lineal - exponencial.

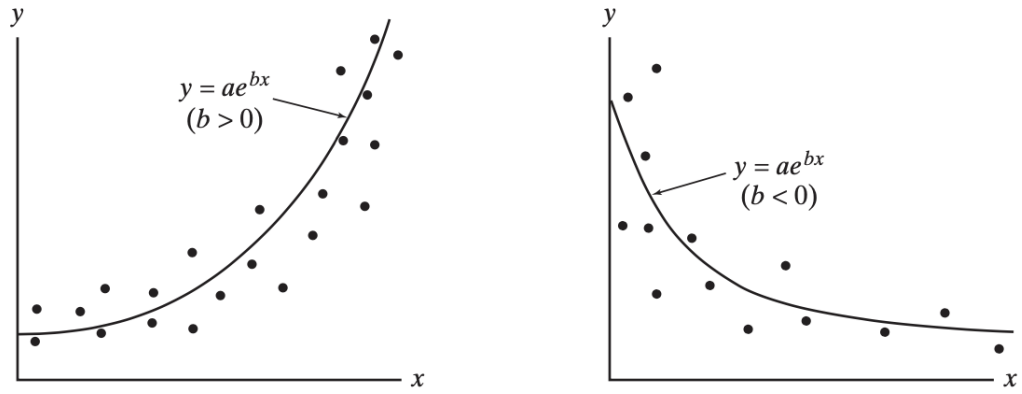

Figura 1.7: Funciones exponenciales, Retomado de Larsen y Marx (2012, p. 532) Larsen y Marx 2012

1.5.2. Regresión logarítmica

En este caso suponemos que los cambios en y por causa de cambios en x son proporcionales a la razón que guardan y y x, es decir:

$$\frac{dy}{dx} = b\frac{y}{x}$$

Por lo que podemos establecer:

$$\frac{dy}{dx} = b\frac{y}{x} \Longleftrightarrow \frac{dy}{y} = b\frac{dx}{x} \Longleftrightarrow \int \frac{dy}{y} = \int b\frac{dx}{x} \Longleftrightarrow ln(y) = a + ln(x)$$

Así, podemos establecer que la forma funcional de la relación de y y x es como sigue y como se muestra en la Figura 1.8.

$$y = kx^b$$

1.5.3. Funciones logísticas

Este tipo de ecuaciones tienen la característica de que permiten modelar crecimientos poblacionales, aceptación de políticas públicas, aceptación de tecnologías, epidemias, etc. En este caso suponemos que enfrentamos que los cambios en y dados los cambios en x son proporcionales a y y a las distancia

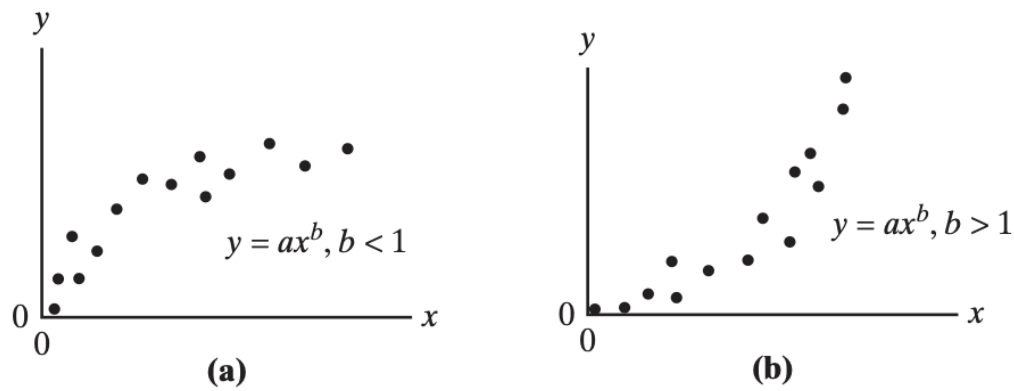

Figura 1.8: Funciones logarítmicas, Retomado de Larsen y Marx (2012, p. 536) Larsen y Marx 2012

que y tiene respecto de un factor de saturación L (límite superior o punto de saturación poblacional, cobertura universal, infecciones en el total de la población, etc.).

En este caso suponemos que la variación estará dada por:

$$\frac{dy}{dx} = ky(L - y)$$

Donde k y L son constantes. Una vez solucionada la ecuación diferencial anterior, encontraremos que, si $L = 1$, entonces l a solución será como sigue, la Figura 1.9 ilustra ecuaciones como la siguiente:

$$y = \frac{1}{1 + e^{a+bx}} \tag{1.13}$$

Ahora mostremos como llegar a la solución de la ecuación logística:

$$\frac{dy}{dx} = ky(L - y) \Longleftrightarrow \frac{dy}{y(L - y)} = kdx \Longleftrightarrow \left(\frac{\frac{1}{L}}{y} + \frac{\frac{1}{L}}{(L - y)}\right) dy = kdx$$

$$\Longleftrightarrow \frac{1}{L}\left(\frac{dy}{y} + \frac{dy}{(L - y)}\right) = kdx \Longleftrightarrow \int \frac{1}{L}\left(\frac{dy}{y} + \frac{dy}{(L - y)}\right) = \int kdx$$

$$\Longleftrightarrow \left(\int \frac{dy}{y} + \int \frac{dy}{(L - y)}\right) = \int Lkdx \Longleftrightarrow (ln(y) - ln(L - y)) = Lkx + C$$

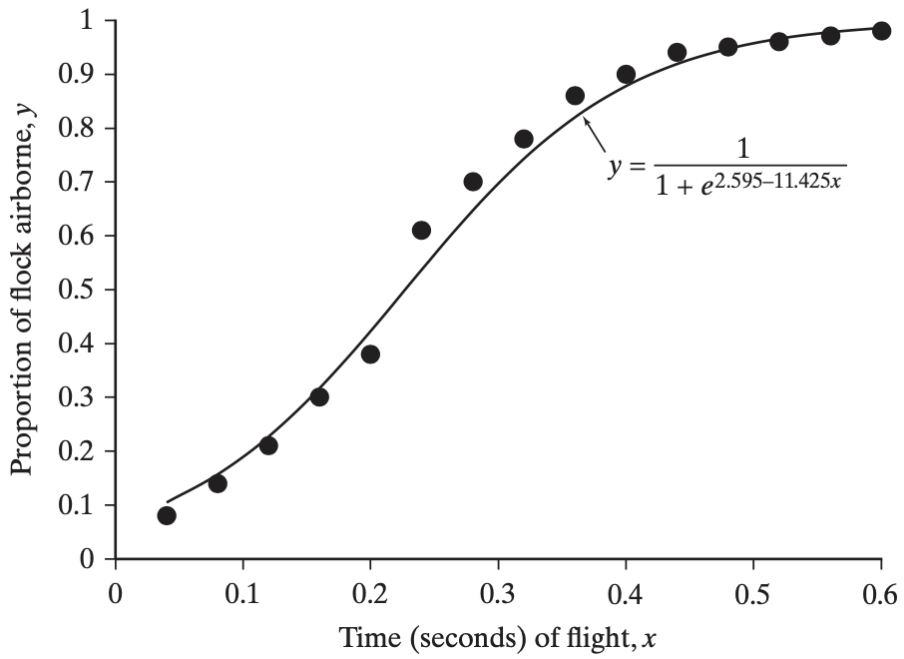

Figura 1.9: Funciones logísticas, Retomado de Larsen y Marx (2012, p. 540) Larsen y Marx 2012

$$\iff (ln(L-y) - ln(y)) = -LC - Lkx \iff ln\left(\frac{L-y}{y}\right) = -LC - Lkx$$

$$\iff \left(\frac{L-y}{y}\right) = e^{-LC-Lkx} \iff y = \frac{L}{1+e^{-LC-Lkx}}$$

Por lo tanto, la solución general de la ecucación será:

$$y = \frac{L}{1+e^{a+bx}}$$

Donde asumimos que la forma lineal de la ecuación logística es:

$$ln\left(\frac{L-y}{y}\right) = a + bx$$

1.6. Modelo de regresión lineal múltiple

En esta sección ampliaremos la discusión de regresión bivariada para introducir más varaibles de forma que ahora supondremos una media condicional como:

$$\mu_{Y|x_1,x_2,\ldots,x_K} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_K x_K = \hat{y}$$

En este caso, como se notará, tenemos $K+1$ parámetros a estimar mediante el método de mínimos cuadrados ordinarios. Por ello, nuestro conjunto de datos será descrito por:

$$\{(x_{i1}, x_{i2}, \ldots, x_{iK}; y_i) : i = 1, 2, \ldots, n\}$$

En este caso podemos ilustrar el término de error con la Figura 1.10. Donde asumiremos que se cumplen los supuestos del modelo lineal, pero para múltiples variables independientes. De esta forma podemos establecer la función:

$$S(\boldsymbol{\beta}) = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

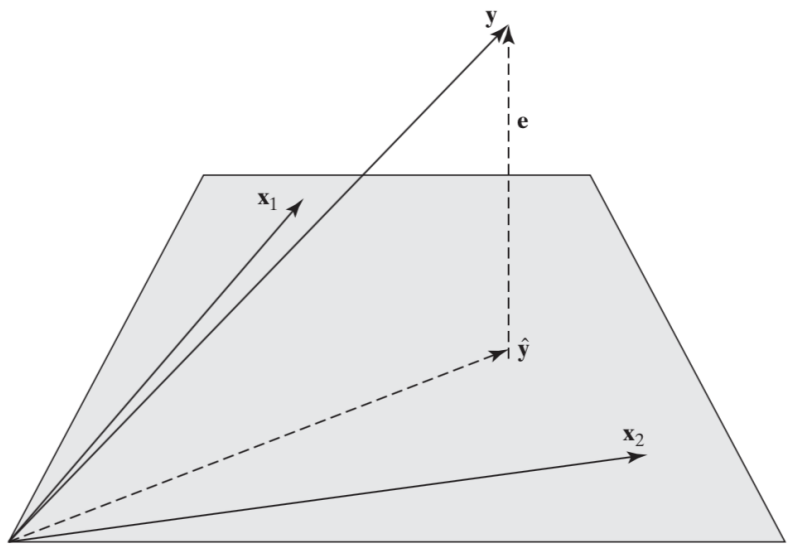

Figura 1.10: Ilustración de la poroyección de y en x_1 y x_2 y el significado del error e, retomado de Greene (2012, pp. 20) Greene 2012

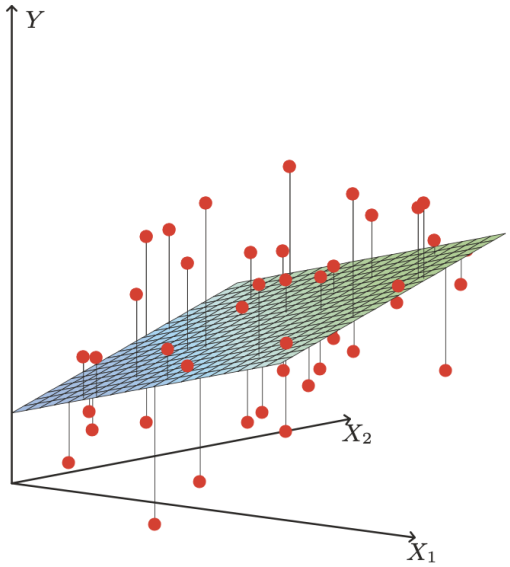

Figura 1.11: Ilustración del hiperplano generado dee regresar X_1 y X_2 en Y, retomado de Hastie, Tibshirani y Friedman (2009, pp. 45) Hastie, Tibshirani y Friedman 2017

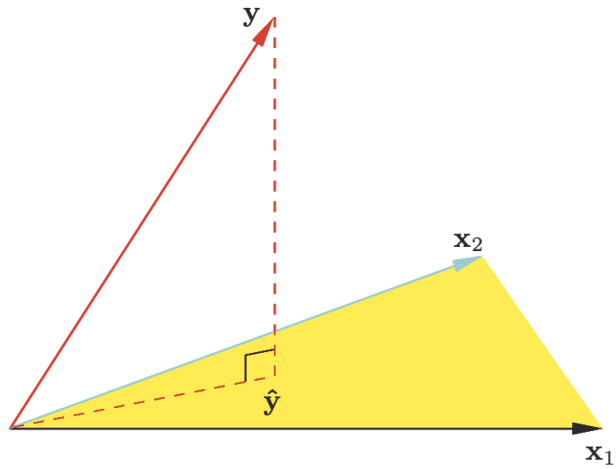

Figura 1.12: Ilustración de la poroyección de y en x_1 y x_2 y el significado del error e, retomado de Hastie, Tibshirani y Friedman (2009, pp. 46) Hastie, Tibshirani y Friedman 2017

Donde:

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix}$$

Entonces nuestro problema consiste en:

$$\min_{\boldsymbol{\beta}} S(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \ldots - \beta_K x_{iK})^2$$

Las $K+1$ condiciones de primer orden estarán dadas por:

$$\begin{aligned}
\frac{\partial S(\boldsymbol{\beta})}{\partial \beta_0} &= -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \ldots - \beta_K x_{iK}) \\
\frac{\partial S(\boldsymbol{\beta})}{\partial \beta_1} &= -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \ldots - \beta_K x_{iK})x_{i1} \\
&\vdots \\
\frac{\partial S(\boldsymbol{\beta})}{\partial \beta_K} &= -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2} - \ldots - \beta_K x_{iK})x_{iK}
\end{aligned}$$

De donde tenemos $K+1$ ecuaciones normales. Resolviendo el siguiente sistema podríamos obtener los estimadores de los parámetros:

$$\begin{aligned}
\sum_{i=1}^{n}(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \ldots - \hat{\beta}_K x_{iK}) &= 0 \\
\sum_{i=1}^{n}(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \ldots - \hat{\beta}_K x_{iK})x_{i1} &= 0 \\
&\vdots \\
\sum_{i=1}^{n}(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \ldots - \hat{\beta}_K x_{iK})x_{iK} &= 0
\end{aligned}$$

¿Cómo resolvemos este sistema? Utilicemos una alternativa. Para ello introduciremos notación matricial. Sean:

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix}$$

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \ldots & x_{1K} \\ 1 & x_{21} & x_{22} & \ldots & x_{2K} \\ 1 & x_{31} & x_{32} & \ldots & x_{3K} \\ \vdots & \vdots & \vdots & \ddots & \ldots \\ 1 & x_{n1} & x_{n2} & \ldots & x_{nK} \end{bmatrix}$$

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix}$$

Bajo esta notación podemos ver que:

$$\mu_{\mathbf{Y}|\mathbf{x}} = \mathbb{E}[\mathbf{Y}|\mathbf{x}] = \mathbf{X}\boldsymbol{\beta}$$

Definamos el vector de errores de la estimación como:

$$\begin{aligned} \mathbf{e} &= \mathbf{Y} - \mathbf{X}\boldsymbol{\beta} \\ \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_n \end{bmatrix} &= \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} - \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1K} \\ 1 & x_{21} & x_{22} & \dots & x_{2K} \\ 1 & x_{31} & x_{32} & \dots & x_{3K} \\ \vdots & \vdots & \vdots & \ddots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nK} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{bmatrix} \end{aligned}$$

De esta forma, definiremos la función:

$$\begin{aligned} S(\boldsymbol{\beta}) &= \sum_{i=1}^{n} e_i^2 = \begin{bmatrix} e_1 & e_2 & e_3 & \dots & e_n \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_n \end{bmatrix} = \mathbf{e}'\mathbf{e} \\ &= (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \\ &= \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}'\mathbf{X}'\mathbf{Y} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta} \\ &= \mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta} \end{aligned}$$

Así, nuestro problema de optimización consiste en:

$$\min_{\boldsymbol{\beta}} S(\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} \mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}$$

En los siguientes pasos utilzaré una propiedad de la derivación de matrices. Sean A, B y C matrices matrices con dimensiones que permiten los

productos: $A \cdot B$ y $B' \cdot C \cdot B$, y además supongamos que la matriz C es simétrica, $C = C'$. Entonces lo siguiente ees cierto:

$$\begin{aligned}
\frac{\partial(A \cdot B)}{\partial B} &= A' \\
\frac{\partial(B' \cdot C \cdot B)}{\partial B} &= 2 \cdot C' \cdot B = 2 \cdot C \cdot B
\end{aligned}$$

Dicho lo anterior, tenemos que el gradiente será:

$$\begin{aligned}
\frac{\partial S(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} &= \frac{\partial}{\partial \boldsymbol{\beta}}(\mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}) \\
&= -2\mathbf{X}'\mathbf{Y} + 2(\mathbf{X}'\mathbf{X})'\boldsymbol{\beta} \\
&= -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\boldsymbol{\beta}
\end{aligned}$$

Donde hemos utilizado que la matriz $\mathbf{X}'\mathbf{X}$ es simétrica (más adelante discutimos esta condición). Finalmente, las condiciones de primer orden serán:

$$-\mathbf{X}'\mathbf{Y} + \mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = 0$$

Si la inversa de la matriz $\mathbf{X}'\mathbf{X}$, entonces la solución de mínimos cuadrados será:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \tag{1.14}$$

Para verificar si es un mínimo:

$$\frac{\partial}{\partial \boldsymbol{\beta}}(-2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\boldsymbol{\beta}) = 2\mathbf{X}'\mathbf{X}$$

Donde esta ecuación es definida positiva. Ahora analicemos cada uno de los componentes de la ecuación (1.14)

$$\begin{aligned}
\mathbf{X}'\mathbf{X} &= \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ x_{11} & x_{21} & x_{31} & \dots & x_{n1} \\ x_{12} & x_{22} & x_{32} & \dots & x_{n2} \\ \vdots & \vdots & \vdots & \ddots & \dots \\ x_{1K} & x_{2K} & x_{3K} & \dots & x_{nK} \end{bmatrix} \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1K} \\ 1 & x_{21} & x_{22} & \dots & x_{2K} \\ 1 & x_{31} & x_{32} & \dots & x_{3K} \\ \vdots & \vdots & \vdots & \ddots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nK} \end{bmatrix} \\
&= \begin{bmatrix} n & \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i2} & \dots & \sum_{i=1}^n x_{iK} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1}x_{i2} & \dots & \sum_{i=1}^n x_{i1}x_{iK} \\ \sum_{i=1}^n x_{i2} & \sum_{i=1}^n x_{i2}x_{i1} & \sum_{i=1}^n x_{i2}^2 & \dots & \sum_{i=1}^n x_{i2}x_{iK} \\ \vdots & \vdots & \vdots & \ddots & \dots \\ \sum_{i=1}^n x_{iK} & \sum_{i=1}^n x_{iK}x_{i1} & \sum_{i=1}^n x_{iK}x_{i2} & \dots & \sum_{i=1}^n x_{iK}^2 \end{bmatrix}
\end{aligned}$$

$$
\begin{aligned}
\mathbf{X}'\mathbf{Y} &= \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ x_{11} & x_{21} & x_{31} & \dots & x_{n1} \\ x_{12} & x_{22} & x_{32} & \dots & x_{n2} \\ \vdots & \vdots & \vdots & \ddots & \dots \\ x_{1K} & x_{2K} & x_{3K} & \dots & x_{nK} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} \\
&= \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1} y_i \\ \sum_{i=1}^n x_{i2} y_i \\ \vdots \\ \sum_{i=1}^n x_{iK} y_i \end{bmatrix}
\end{aligned}
$$

Ahora verifiquemos las propiedades del estimador que teníamos pendientes de la regresión bivariada. Partiendo de la ecuación (1.14), tenemos :

$$
\begin{aligned}
\mathbb{E}[\hat{\boldsymbol{\beta}}|\mathbf{x}] &= \mathbb{E}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}|\mathbf{x}] \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{Y}|\mathbf{x}] \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} \\
&= \boldsymbol{\beta}
\end{aligned}
$$

Por lo tanto el estimador de mínimos cuadrados ordinarios es insesgado. Analicemos ahora la varianza:

$$
\begin{aligned}
Var[\hat{\boldsymbol{\beta}}|\mathbf{x}] &= \mathbb{E}[(\hat{\boldsymbol{\beta}} - \mathbb{E}[\hat{\boldsymbol{\beta}}|\mathbf{x}])(\hat{\boldsymbol{\beta}} - \mathbb{E}[\hat{\boldsymbol{\beta}}|\mathbf{x}])'|\mathbf{x}] \\
&= \mathbb{E}[((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} - \boldsymbol{\beta})((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} - \boldsymbol{\beta})'|\mathbf{x}] \\
&= \mathbb{E}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}\mathbf{Y}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}\boldsymbol{\beta}' \\
&\quad -\boldsymbol{\beta}\mathbf{Y}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} + \boldsymbol{\beta}\boldsymbol{\beta}'|\mathbf{x}] \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \cdot \mathbb{E}[\mathbf{Y}\mathbf{Y}'|\mathbf{x}] \cdot \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\
&\quad -(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \cdot \mathbb{E}[\mathbf{Y}|\mathbf{x}] \cdot \boldsymbol{\beta}' \\
&\quad -\boldsymbol{\beta} \cdot \mathbb{E}[\mathbf{Y}'|\mathbf{x}] \cdot \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} + \boldsymbol{\beta}\boldsymbol{\beta}' \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \cdot \mathbb{E}[\mathbf{Y}\mathbf{Y}'|\mathbf{x}] \cdot \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta}\boldsymbol{\beta}' \\
&\quad -\boldsymbol{\beta}\boldsymbol{\beta}'\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} + \boldsymbol{\beta}\boldsymbol{\beta}' \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \cdot \mathbb{E}[\mathbf{Y}\mathbf{Y}'|\mathbf{x}] \cdot \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} - \boldsymbol{\beta}\boldsymbol{\beta}' - \boldsymbol{\beta}\boldsymbol{\beta}' + \boldsymbol{\beta}\boldsymbol{\beta}' \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \cdot \mathbb{E}[\mathbf{Y}\mathbf{Y}'|\mathbf{x}] \cdot \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} - \boldsymbol{\beta}\boldsymbol{\beta}' \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\sigma^2\mathbb{I}_n - \mathbf{X}'\boldsymbol{\beta}'\boldsymbol{\beta}\mathbf{X})\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} - \boldsymbol{\beta}\boldsymbol{\beta}' \\
&= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}
\end{aligned}
$$

De esta forma planteamos que:

$$\hat{\boldsymbol{\beta}} \sim N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$$

Ahora, partiendo de que $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$, requerimos de determinar:

$$\begin{aligned}
\mathbb{E}[\mathbf{e}'\mathbf{e}|\mathbf{x}] &= \mathbb{E}[(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})|\mathbf{x}] \\
&= \mathbb{E}[(\mathbf{Y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y})'(\mathbf{Y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y})|\mathbf{x}] \\
&= \mathbb{E}[(\mathbf{Y}' - \mathbf{Y}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')(\mathbf{Y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y})|\mathbf{x}] \\
&= \mathbb{E}[\mathbf{Y}'(\mathbb{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')(\mathbb{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\mathbf{Y}|\mathbf{x}] \\
&= \mathbb{E}[tr(\mathbf{e}'\mathbf{e})|\mathbf{x}] \\
&= \mathbb{E}[tr((\mathbb{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\mathbf{Y}\mathbf{Y}')|\mathbf{x}] \\
&= tr((\mathbb{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\mathbb{E}[\mathbf{Y}\mathbf{Y}'|\mathbf{x}]) \\
&= tr((\mathbb{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')(\sigma^2\mathbf{I}_n - \mathbf{X}\boldsymbol{\beta}\boldsymbol{\beta}'\mathbf{X}')) \\
&= tr(\sigma^2\mathbb{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') \\
&= tr(\sigma^2\mathbb{I}_n) - tr(\sigma^2\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') \\
&= \sigma^2 tr(\mathbb{I}_n) - \sigma^2 tr(\mathbb{I}_{K+1}) \\
&= \sigma^2(n - (K+1))
\end{aligned}$$

De esta forma utilizaremos un estimador de la varianza σ^2 que es insesgado:

$$\hat{\sigma}^2 = \frac{\mathbf{e}'\mathbf{e}}{n - (K+1)}$$

De esta forma podemos plantear la distribución muesral de los parámetros $\boldsymbol{\beta}$ como:

$$\begin{aligned}
\hat{\boldsymbol{\beta}} &\sim N(\boldsymbol{\beta}, \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}) \\
\hat{\sigma}^2 &= \frac{\mathbf{e}'\mathbf{e}}{n - (K+1)}
\end{aligned}$$

Dado que desconocemos la varianza de la distribución de $\mathbf{Y}$ y $\mathbf{X}$ utilizaremos una transformación t-Student de la siguiente forma:

$$T = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}_{kk}}} \sim t_{[n-(K+1)]}$$

Donde $(\mathbf{X}'\mathbf{X})^{-1}_{kk}$ es la posición (k,k) de la matriz $(\mathbf{X}'\mathbf{X})^{-1}$. De esta forma podemos establecer una pruba de hipótesis para cada una de las β_k's como:

$$\begin{aligned} H_0 &: \hat{\beta}_k = \beta_{k,0} \\ H_a &: \begin{cases} \hat{\beta}_k > \beta_{k,0} \\ \hat{\beta}_k < \beta_{k,0} \\ \hat{\beta}_k \neq \beta_{k,0} \end{cases} \end{aligned}$$

Para la cual podemos utilizar la misma regla de rechazo que ya hemos estudiado en la sección de prueba de hipótesis.

De forma complementaria podemos establecer hipótesis sobre combinaciones lineales de los estimadores de $\boldsymbol{\beta}$. Las cuales podemos platear como:

$$\begin{aligned} H_0 &: \mathbf{R}\hat{\boldsymbol{\beta}} = q \\ H_a &: \begin{cases} \mathbf{R}\hat{\boldsymbol{\beta}} > q \\ \mathbf{R}\hat{\boldsymbol{\beta}} < q \\ \mathbf{R}\hat{\boldsymbol{\beta}} \neq q \end{cases} \end{aligned}$$

Donde $\mathbf{R}$ es un vector de dimensión $1 \times (K+1)$ de restricciones que toma el valor de 0 y 1 de acuerdo con la restricción que queramos evaluar, y q es el valor que asumimos como cierto y queremos evaluar. De forma similar planteamos la transformación a evaluar como:

$$T = \frac{\mathbf{R}\hat{\boldsymbol{\beta}} - q}{\sqrt{\hat{\sigma}^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'}} \sim t_{[n-(K+1)]}$$

Definamos a F de Fisher como la razón de dos pruebas t de Student, la primera para los valores de una combinación lineal de $\hat{\boldsymbol{\beta}}$, y la segunda para el estimador de la varianza $\hat{\sigma}^2$:

$$\begin{aligned} \mathbf{F} &= \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})/J}{\hat{\sigma}^2} \\ &= \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{J} \\ &= \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}Var(\hat{\boldsymbol{\beta}})\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{J} \end{aligned}$$

Por lo tanto la estadística F de prueba será:

$$F = \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{J} \sim F_{J,n-K} \tag{1.15}$$

Así, la prueba de hipótesis que es la más común en el análisis de regresión y que se le conoce como prueba global. Dicha prueba asume una forma de la matriz **R** definida así:

$$\mathbf{R} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

Y un vector **r**:

$$\mathbf{r} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

De esta forma la hipotésis nula de una prueba global se puede escribir como:

$$\begin{aligned} H_0 : &\quad \beta_1 = \beta_2 = \ldots = \beta_K = 0 \\ H_a : &\quad NoH_0 \end{aligned}$$

Esta prueba se le conoce como prueba global, ya que prueba si en conjunto todas las variables independientes tienen un efecto nulo en **Y**.

Ejemplo. Suponga que tiene datos de precios y cantidades mostrados en el Cuadro 1.1. Con dichos datos estima la ecuación:

$$Q_i = \beta_0 + \beta_1 P_i$$

De esta forma la matriz **X** y vector **Y** serán como sigue:

$$\mathbf{X} = \begin{bmatrix} 1 & 3 \\ 1 & 3 \\ \vdots & \vdots \\ 1 & 9 \end{bmatrix}$$

$$\mathbf{Y} = \begin{bmatrix} 18 \\ 16 \\ \vdots \\ 8 \end{bmatrix}$$

Cuadro 1.1: Tabla de Precios y Cantidades

P	Q
3	18
3	16
7	17
6	12
10	15
15	15
16	4
13	13
9	11
15	8
9	8

De esta forma los estimadores de $\boldsymbol{\beta}$ seran:

$$\hat{\boldsymbol{\beta}} = \begin{bmatrix} 18.3977 \\ -0.6356 \end{bmatrix}$$

Una vez estimados los parámetros podemos gráficar los puntos en la muestra la recta (ver Figura 1.13).

Ejemplo. Suponga que ha estimado una ecuación de regresión del precio de las casas. Su estimación se rigue por la siguiente ecuación:

$$ln(P) = \beta_0 + \beta_1 ln(AreaM^2) + \beta_2 \#Recamaras + \beta_3 \#Banios + \beta_4 Antiguedad$$

La estimación de dicha ecuación se reporta el en Cuadro 1.2, en el que se le pide que complete la columa de T-Estadística y determine si en cada caso acepta o rechaza la hipótesis:

$$\begin{aligned} H_0 &: \hat{\beta}_k = 0 \\ H_1 &: \hat{\beta}_k \neq 0 \end{aligned}$$

Asimismo, utilicemos la siguiente transformación:

$$T = \frac{\hat{\beta}_k - 0}{\sqrt{\hat{\sigma}^2 (\mathbf{X}'\mathbf{X})^{-1}_{kk}}} = \frac{\hat{\beta}_k - 0}{\text{Errror Estándar}} \sim t_{[n-(K+1)]}$$

Donde $k = 0, 1, 2, 3, 4$ y $n = 100$.

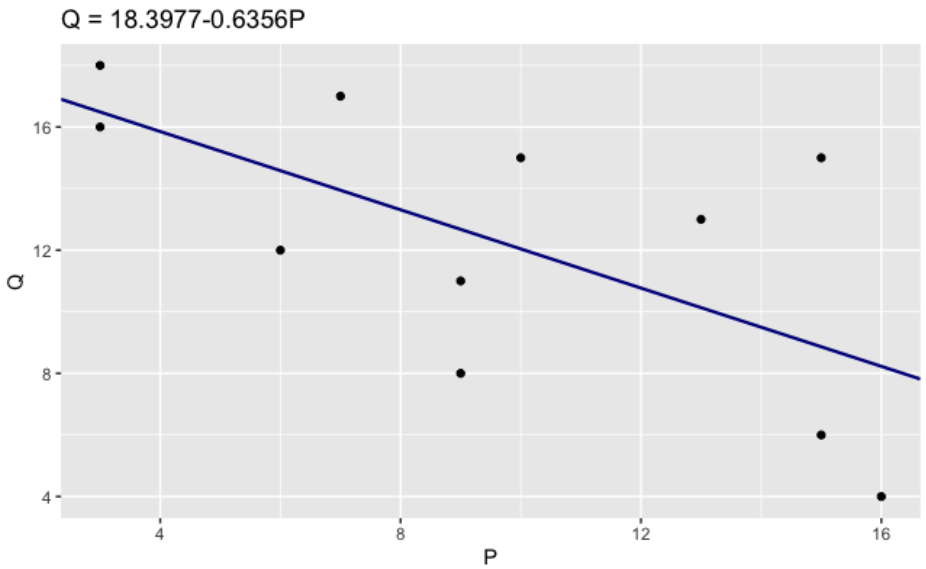

Figura 1.13: Gráfica de Precios y Cantidades, y su recta de regresión

Cuadro 1.2: Regresión resultados

$\hat{\beta}_k$	Coeficiente	Error Estándar	T-Estadística
β_0	7.094	0.232	
β_1	0.400	0.028	
β_2	0.078	0.015	
β_3	0.216	0.023	
β_4	0.212	0.024	

2

Aprendizaje no supervisado - Técnicas de Clúster

2.1. Análisis de Componentes Principales

El análisis de componentes principales (PCA, por sus siglas en inglés) es una herramienta importante y útil de aprendizaje no supervisado para la reducción de dimensiones. El PCA se puede utilizar como una herramienta para el preprocesamiento de datos antes de que se apliquen técnicas de aprendizaje supervisado. El PCA produce una representación de baja dimensión de un conjunto de datos. Encuentra secuencialmente un conjunto de combinaciones lineales de los predictores que tienen una varianza máxima y son ortogonales entre sí.

El análisis de componentes principales asume que las variables individuales pueden ser descritas por una combinación lineal de factores; es decir, esos factores representan completamente la varianza de las variables. El primer componente principal de un conjunto de características denominadas como $X_1, X_2, \ldots, X_K$ es la combinación lineal de las características o predictores X:

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \ldots + \phi_{K1}X_K \tag{2.1}$$

que tiene la mayor varianza, donde ϕ_{j1} satisface:

$$\sum_{j=1}^{K} \phi_{j1}^2 = 1 \tag{2.2}$$

Los coeficientes ϕ_{ji} se llaman cargas y se pueden encontrar utilizando una descomposición en valores singulares de la matriz X de dimensión $n \times K$. El segundo componente principal es la combinación lineal de $X_1, \ldots, X_K$ que tiene máxima varianza entre todas las combinaciones lineales que son ortogonales con Z_1. Así, el segundo componente sería:

$$Z_2 = \phi_{12}X_1 + \phi_{22}X_2 + \ldots + \phi_{K2}X_K \tag{2.3}$$

donde el coeficiente ϕ_2 es el vector de carga del segundo componente principal, satisfaciendo $\phi_1 \cdot \phi_2 = 0$, es decir, $\phi_1 \perp \phi_2$. Este proceso continúa hasta que se encuentren todos los componentes principales $K^* = \text{mín}(n - 1, K)$. Aquí, los productos internos $\phi_i \cdot \phi_j = 0$ y $Z_i \cdot Z_j = 0$ para todos $i \neq j$.

El significado de las cargas se puede interpretar de la siguiente manera:

1. El vector de carga ϕ_1 con elementos $\phi_{11}, \phi_{21}, \ldots, \phi_{K1}$ define una dirección en el espacio de características a lo largo de la cual los datos varían más.

2. Las direcciones de los componentes principales $\phi_1, \phi_2, \ldots, \phi_K$ son la secuencia ordenada de vectores singulares derechos de la matriz X, y las varianzas de los componentes son $1/n$ veces los cuadrados de los valores singulares.

3. El vector de carga ϕ_1 define la línea en el espacio K-dimensional que está más cerca de las n observaciones en términos de distancia euclidiana cuadrada media.

Asumiendo que las variables han sido centradas para tener media cero, la varianza total observada es:

$$\sum_{j=1}^{K} \text{Var}(X_j) = \sum_{j=1}^{K} \frac{1}{n} \sum_{i=1}^{n} x_{ij}^2. \tag{2.4}$$

y la varianza explicada por el m-ésimo componente principal es:

$$\text{Var}(Z_m) = \frac{1}{n} \sum_{i=1}^{n} z_{im}^2. \tag{2.5}$$

Por lo tanto, la varianza proporcional explicada por el m-ésimo componente principal se da por la cantidad positiva entre 0 y 1.

$$\frac{\sum_{i=1}^{n} z_{im}^2}{\sum_{j=1}^{K} \sum_{i=1}^{n} x_{ij}^2}. \tag{2.6}$$

Una de las desventajas de usar PCA es que las características transformadas Z no son tan intuitivas como las medidas originales X; reduciendo las posibilidades de interpretación.

2.2. Análisis Factorial

El análisis factorial o análisis de factores usa la correlación entre los artículos o elementos individuales para reducirlos a un número pequeño de dimensiones independientes o factores, sin suponer la unidimensionalidad de la escala. La matriz de correlación de los elementos indica cuales exhiben patrones similares de respuesta. Esos elementos son agrupados en factores.

En contraste con el análisis de componentes principales, el análisis de factores o factorial asume que la varianza de la variable puede ser separada en 2 partes. La primera está determinada por la varianza conjunta de todas las variables incluidas en el análisis. La otra parte está determinada por la varianza especifica de la variable en cuestion. Bajo el enfoque de análisis de factores, los factores explican solo el primer componente de la varianza.

Después de checar la

2.3. Clúster

El término clúster refiere a un grupo de individuos u objetos que convergen alrededor de cierto punto y son relativamente cercanos en su posición. En astronomía, existen clústeres de estrellas; en química hay clústeres de atomos. En el campo de la economía en ocasiones se refiere a técnicas que consideran grupos dentro del total de la población. Por ejemplo, las empresas que buscan analizar un grupo de potenciales clientes podrían buscar dividir el total de consumidores en segmentos o clústeres.

El proposito del análisis de clúster es identificar clústeres homogéneos dentro de un conjunto de individuos u objetos heterogéneos. No obstante, hay un mal entendido muy común en el análisis de clúster. Este es la creencia de que existe sólo un tipo de técnica de análisis de clúster. En la realidad, existen muchas técnicas de clústering. Esto se deriva de que existen una

amplia variedad de métricas de distancia y algoritmos de agrupamiento que pueden ser usados.

En general, se pueden identificar 2 tipos generales de métodos de clúster:

1. Análisis de agrupamiento del tipo k-Means

2. Análisis de clúster jerárquico

El agrupamiento o clustering se refiere a un conjunto muy amplio de técnicas para encontrar subgrupos, o clústeres, en un conjunto de datos. El objetivo del agrupamiento es encontrar una partición de los datos en grupos distintos de modo que las observaciones dentro de cada grupo sean bastante similares entre sí en algún sentido. Tal sentido de similitud a menudo es una consideración específica del dominio que debe realizarse con base en el conocimiento de los datos que se estudian. La similitud debe estar relacionada con algún resultado vago o posibles múltiples resultados/propósitos.

En las bibliotecas, organizamos los libros por diferentes categorías y subcategorías, mientras que tales selecciones de categorías y subcategorías se basan en las necesidades de los clientes que a menudo no están claramente definidas. En casa, organizamos nuestras cosas en ropa, zapatos, utensilios de cocina y otros para conveniencia cuando los usamos. Por lo tanto, el agrupamiento debe tener algunos propósitos que son difíciles de caracterizar usando una medida de resultado simple. Por esta razón, el aprendizaje supervisado no es aplicable al problema.

Un buen ejemplo de agrupamiento en el comercio sería el agrupamiento para la segmentación del mercado. Supongamos que tenemos acceso a grandes datos (por ejemplo, ingreso medio del hogar, ocupación, distancia desde el área urbana más cercana) de un gran número de personas que pueden o no ser nuestros clientes existentes. Nuestro objetivo es identificar subgrupos de personas que podrían ser más receptivas a una forma particular de publicidad, o agruparlos (en términos de datos) de acuerdo con la probabilidad de comprar un producto en particular.

A diferencia del PCA, que busca una representación de baja dimensión de las observaciones que explica una buena fracción de la varianza, el agrupamiento busca subgrupos homogéneos entre las observaciones.

Hay dos métodos de agrupamiento comúnmente utilizados: el agrupamiento K-medias y el agrupamiento jerárquico. En el agrupamiento K-medias, buscamos particionar las observaciones en un número preespecificado de

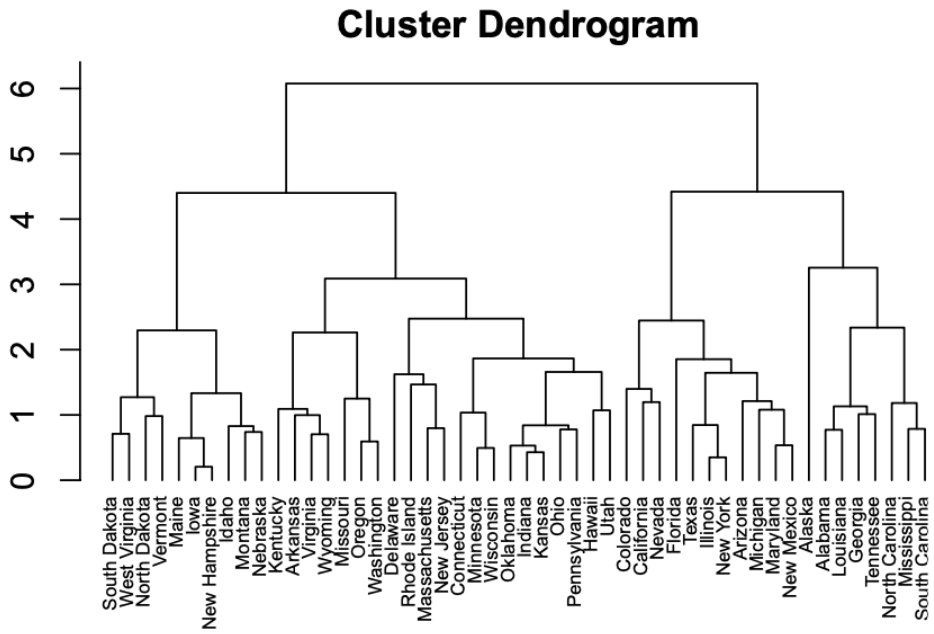

Figura 2.1: US Arrest Hierarchical Clustering, retomado de Chang (2020, p 216) Chang 2020

clústeres, mientras que en el agrupamiento jerárquico no sabemos de antemano cuántos clústeres queremos. En cambio, el agrupamiento jerárquico terminará con una representación visual en forma de árbol de las observaciones, llamada dendrograma, que nos permite ver de una vez el agrupamiento obtenido para cada número posible de clústeres (Figura 2.1). d

2.3.1. K-Means Clustering

Algoritmo K-Means

El clústering K-Means es un método de análisis que agrupa observaciones en clústeres. Las principales diferencias entre k-means y el clústering jerárquico es que los usuarios de k-means deciden el número de clústeres desde el inicio. Es decir, desde un inicio, determinamos una partición inicial que asumimos.

El algoritmo de k-means tiene los siguientes requerimientos:

1. Conocimiento sobre el mejor número de clústeres.

2. Las variables deberian estar transformadas como con la transformación z.

El algoritmo K-medias es uno de los métodos de agrupamiento más simples y populares. Sea $X = \{x_i; i = 1, \ldots, n\}$ y el clúster $C = \{c_j; j = 1, \ldots, k\}$. Para un k dado, el objetivo del agrupamiento es encontrar C, tal que

$$\min_{c_j;j} \sum_{i=1}^{n} ||x_i - c_j|| \tag{2.7}$$

El algoritmo K-medias se describe de la siguiente manera:

1. Escoger aleatoriamente k puntos de datos de X como el clúster inicial C.

2. Reasignar todos $x_i \in X$ al promedio de clúster más cercano c_j.

3. Actualizar todos $c_j \in C$ con la media de sus clústeres correspondientes.

4. Repetir los pasos 2 y 3 hasta que las asignaciones de clúster no cambien.

La convergencia del algoritmo está garantizada en un número finito de iteraciones. Sin embargo, cuando la distancia $\sum_{i=1}^{n} ||x_i - c_j||$ es una función no convexa, la convergencia puede llevar a un óptimo local. El algoritmo también es sensible a los valores atípicos y podría llevar a algunos clústeres vacíos. Aquí hemos asumido que k es fijo. El problema de agrupamiento con k variable es muy desafiante desde el punto de vista del cálculo.

El agrupamiento K-medias (k-medoids) ajusta exactamente k clústeres como se especifica y la asignación final de clústeres depende de los centros de clústeres iniciales elegidos y del clúster final asignado.

2.3.2. Clustering Jerárquico

El agrupamiento jerárquico busca construir una jerarquía de clústeres. Las estrategias para el agrupamiento jerárquico pueden ser aglomerativas o divisivas. Una estrategia aglomerativa es un enfoque de abajo hacia arriba, es decir, cada observación comienza en su propio clúster, y pares de clústeres se fusionan a medida que se asciende en la jerarquía. Una estrategia divisiva

es un enfoque de arriba hacia abajo, es decir, todas las observaciones comienzan en un clúster, y se realizan divisiones de forma recursiva a medida que se desciende en la jerarquía. Por su parte, el agrupamiento divisivo con una búsqueda exhaustiva tiene una complejidad de $O(2^n)$, pero es común utilizar heurísticas más rápidas para elegir las divisiones, como K-Medias. Los resultados del agrupamiento jerárquico generalmente se presentan en un dendrograma.

Para decidir qué clústeres se deben combinar (estrategia aglomerativa) o dónde se debe dividir un clúster (estrategia divisiva), se requiere una medida de disimilitud o similitud entre conjuntos de observaciones, como distancia o enlace entre pares de observaciones. La distancia puede ser Euclidiana, Euclidiana al cuadrado, Manhattan, máxima, Mahalanobis, entre otras. El criterio de enlace puede ser agrupamiento de enlace completo, $\text{máx}\{d(a,b); a \in A, b \in B\}$, agrupamiento de enlace simple, $\text{mín}\{d(a,b); a \in A, b \in B\}$, o agrupamiento de enlace promedio, $\frac{1}{|A|\cdot|B|}\sum_{a\in A}\sum_{b\in B} d(a,b)$. El enlace simple sufre de encadenamiento porque para fusionar dos grupos, solo se necesita que un par de puntos esté cerca, independientemente de todos los demás. Por lo tanto, los clústeres pueden estar demasiado dispersos. En contraste, el enlace completo evita el encadenamiento, pero sufre de hacinamiento. El enlace promedio intenta, utilizando la disimilitud promedio por pares, establecer un equilibrio.

Una lección importante que la experiencia ha mostrado es que las medidas de distancia en el análisis de clúster deben basarse en unidades comparables de medida. Si las características consideradas en el análisis de clúster están en unidades distintas, las variables podrían pasarse por una de las posibles técnicas de unificación de medida. Usualmente, esto se logra mediante la aplicación de la transformación z de todas las variables con el objetivo de estándarizarlas.

Existen 5 métodos de vinculación para clústering jerárquico aglomerativo:

1. Método simple de vinculación que usa la cercanía de 2 observaciones de 2 clústeres como la base de la medida de distancia.

2. Método de vinculación completa que, en contraste, usa las 2 observaciones de 2 clústeres más lejanos como la base de la distancia.

3. Método de vinculación del centroide que calcula el punto medio para cada clúster de sus observaciones.

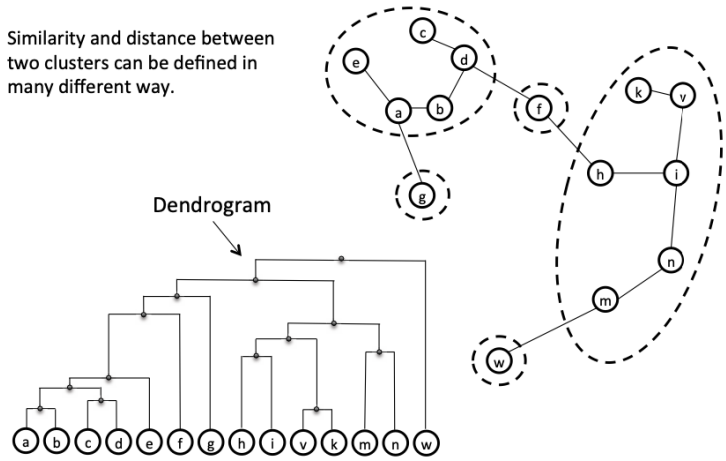

Figura 2.2: Agglomerative Clustering Algorithm and Dendrogram, retomado de Chang (2020, p 219) Chang 2020

4. Método de vinculación promedio que determina la media de la distancia entre las observaciones de 3 clústeres.

5. Método de Ward (propuesto por Joe H. Ward en 1963) que vincula clústeres que optimizan un criterio especifico: la suma de los errores al cuadrado. Este criterio minimiza la varianza total dentro del clúster. Al igual que otros métodos jerárquicos, este inicia mirando cada observaciones como si fuera en si mismo un clúster. En este caso, la suma de errores al cuadrado asume el valor de cero, como la media de cada observación. Para calcular la suma de errores para todas las posibles combinaciones de siguientes vínculos se elije los clústeres que tienden a incrementar poco la suma de errores.

2.3.3. Método de K-means con datos de epidemiológicos.

El código del ejemplo se encuentra en GitHub con el nombre: "06_Unsupervised_Clusteing_Algorithms_KMeans" en GitHub.

2.3.4. Agrupamiento de datos de series temporales

Las observaciones reales de series temporales se pueden agrupar, así como las características extraídas de las mismas, en clusters. Las características se extraen en los dominios de tiempo, frecuencia y ondículas.

La agrupación mediante características del dominio temporal son autocorrelaciones, autocorrelaciones parciales y correlaciones cruzadas. Mientras que, en el dominio de la frecuencia, se extraen características como el periodograma y las ordenadas espectrales y cepstrales. Por último, las características extraídas en el dominio de wavelets son las transformadas discretas de ondículas, las varianzas de ondículas y las correlaciones de ondículas.

Medidas de Distancia

En muchos casos, se utiliza el análisis de clustering tradicional, es decir, el clustering jerárquico, para agrupar series temporales. En este caso, primero se define una medida de distancia adecuada que hereda las características dinámicas de la serie temporal para comparar series temporales, y luego se aplica un análisis de clustering jerárquico estándar utilizando la distancia definida.

Sea $\mathbf{X} = \{x_{ij} : i = 1, \ldots, I;\ j = 1, \ldots, J\} = \{\mathbf{x}_i = (x_{i1}, \ldots, x_{ij}, \ldots, x_{iJ})' : i = 1, \ldots, I\}$ la matriz de datos dónde x_{ij} representa la j-ésima variable observada en el i-ésimo elemento y $\mathbf{x}_i$ representa el vector de la i-ésima observación. La clase más común de medida de distancia utilizada en el análisis de clusters es la clase de distancia de Minkowski.

$$ {}_r d_{il} = \left[\sum_{j=1}^{J} |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, \qquad r \geq 1. \tag{2.8} $$

Para $r = 1$, tenemos la distancia Manhattan:

$$ {}_1 d_{il} = \sum_{j=1}^{J} |x_{ij} - x_{lj}| \tag{2.9} $$

y para $r = 2$, tenemos la distancia Euclidiana:

$$ {}_2 d_{il} = \left[\sum_{j=1}^{J} (x_{ij} - x_{lj})^2 \right]^{\frac{1}{2}} \tag{2.10} $$

Las versiones ponderadas de las anteriores distancias de clase Minkowski son:

$$ {}_r\tilde{d}_{il} = \left[\sum_{j=1}^{J} w_j^r \, |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, \qquad r \geq 1 \tag{2.11} $$

y entonces,

$$ {}_1\tilde{d}_{il} = \sum_{j=1}^{J} w_j^1 \, |x_{jl} - x_{lj}| \qquad (r = 1) \quad \text{(distancia Manhattan ponderada)} $$

$$ {}_2\tilde{d}_{il} = \left[\sum_{j=1}^{J} w_j^2 \, (x_{jl} - x_{lj})^2 \right]^{\frac{1}{2}} \quad (r = 2) \quad \text{(distancia Euclidiana ponderada)} \tag{2.12} $$

dónde $w_j \, (j = 1, \ldots, J)$ representa una ponderación adecuada para la j-ésima variable.

Para utilizar las medidas de distancia en clustering jerárquico es útil obtener las distancias para cada par de unidades en forma de una matriz cuadrada. La matriz de distancia Minkowski puede ser representada de la siguiente manera:

$$ {}_r\mathbf{D} = \left\{ {}_r d_{il} = \left[\sum_{j=1}^{J} |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}} : \; i, l = 1, \ldots, I \right\}, \qquad r \geq 1 \tag{2.13} $$

Clustering Jerárquico Aglomerativo

Los métodos aglomerativos producen una serie de particiones de los datos: el primero consiste en un cluster I de un solo miembro; el último consiste en un solo cluster que contiene todas las unidades I. El clustering aglomerativo comienza con I clusters, donde cada uno incluye exactamente un punto de los datos. Posteriormente, sucede una serie de operaciones de unión que eventualmente fuerza a todos los objetos en un mismo grupo. El clustering aglomerativo general puede ser resumido por el siguiente procedimiento:

1. Empieza con I clusters únicos (singleton). Calcula la matriz de distancias para los I clusters;

2. En la matriz de distancia, busca la mínima distancia $d(C_p, C_q) = \min_{\substack{1 \leq p,q \leq I \\ p \neq q}} d(C_p, C_q)$, dónde $d(\cdot, \cdot)$ es la función de distancia, y por último combina los cluster C_c y $C_{c'}$ para formar el nuevo cluster $C_{cc'}$;

3. Actualiza la matriz de distancia calculando las distancias entre el cluster $C_{cc'}$ y los demás clusters;

4. Repite los pasos 2 y 3 hasta que solo quede un cluster.

La unión de un par de clusters, o la formación de un nuevo cluster depende de como esté definida la función de distancia entre dos clusters. A continuación se presentan de forma breve algunas fromas de definir la función de distancia.

- *Método de enlace simple*: La distancia entre un par de clusters está determinada por las dos unidades más cercanas a los diferentes clusters. El clustering por enlace simple tiende a generar clusters alargados, lo que causa el efecto de encadenamiento. Como resultado, dos clusters con propiedades muy diferentes pueden estar conectados debido a la existencia de perturbaciones. Sin embargo, si los cluster están muy separados, el método de enlace simple funciona bien.

- *Método de enlace completo*: A diferencia del enlace simple, el método de enlace completo utiliza la distancia más lejana de un par de objetos para definir la distancia entre grupos.

- *Método de enlace de promedios grupales*: La distancia entre dos clusters se define como el promedio de las distancias entre todos los pares de puntos de datos, cada uno de los cuales proviene de un cluster diferente.

- *Método de enlace de promedios ponderados*: Similar a los promedios grupales, el enlace promedio también se utiliza para calcular la distancia entre dos clusters. La diferencia radica en que las distancias entre el cluster recién formado y el resto se ponderan en función del número de puntos de datos en cada cluster.

- *Método de enlace de centroides*: Dos clusters se unen según la distancia de sus centroides (media).

- *Método de Ward o de la mínima varianza*: El objetivo del método de Ward es minimizar el aumento de la suma intraclase de los errores cuadrados.

Clustering No Jerárquico

A diferencia del clustering jerárquico, que genera un nivel sucesivo de clusters mediante fusiones o divisiones iterativas, el clustering no jerárquico o por particiones asigna un conjunto de puntos de datos en c clusters sin ninguna estructura jerárquica. Este proceso suele acompañar la optimización de una función criterio, normalmente la minimización de una función objetivo que representa la variabilidad interna de los clusters.

Método de clustering por c-Medias

Tambien conocido como k-Medias, el método c-Medias busca una partición óptima de los datos minimizando el criterio de suma de errores al cuadrado con un procedimiento de optimización iterativo, que pertenece a la categoría de algoritmos hill-climbing. El procedimiento básico de clustering de c-Medias se resume de la siguiente manera:

1. Inicie con c particiones aleatorias o basadas en algún conocimiento previo. Calcule los prototipos de clusters (centroides o medias),es decir, calcule la media de cada cluster considerando solo las observaciones que pertenecen a cada cluster.

2. Asigne cada unidad del conjunto de datos al grupo más cercano utilizando una medida de distancia adecuada entre cada par de unidades y centroides.

3. Recalcular los prototipos de clusters (centroides o medias) en función de la partición actual.

4. Repita los pasos 2 y 3 hasta que no haya cambios para cada cluster.

El método de c-Medias formalizado matemáticamente es de la siguiente forma:

$$\text{mín} : \sum_{i=1}^{I} \sum_{c=1}^{C} u_{ic}\, d_{ic}^2 = \sum_{i=1}^{I} \sum_{c=1}^{C} u_{ic}\, \|\mathbf{x}_i - \mathbf{h}_c\|^2, \tag{2.14}$$

$$\sum_{c=1}^{C} u_{ic} = 1, \quad u_{ic} \geq 0, \quad u_{ic} \in \{0, 1\} \tag{2.15}$$

donde u_{ic} indica el grado de pertenencia de la unidad i-ésima al clúster c-ésimo; $u_{ic} \in \{0, 1\}$, es decir, $u_{ic} = 1$ cuando la unidad i-ésima pertenece al clúster c-ésimo; $u_{ic} = 0$ en caso contrario; $d_{ic}^2 = \|\mathbf{x}_i - \mathbf{h}_c\|^2$ indica la distancia euclidiana al cuadrado entre el objeto i-ésimo y el centroide del clúster c-ésimo.

Método de clustering por c-Medoides.

Las unidades se clasifican en clusters representados por uno de los puntos de datos del cluster. Estos puntos de datos son los prototipos, los llamados medoides. Cada medoide sintetiza la información del cluster y representa las características prototípicas de los clusters, y luego sintetiza las características de las unidades pertenecientes a cada cluster. Siguiendo el método de agrupamiento de c-medoides, minimizamos la función objetivo representada por la suma de la disimilitud de las unidades con sus unidades representativas más cercanas. El método de clustering por c-medoides primero calcula un conjunto de unidades representativas, los medoides. Tras encontrar el conjunto de medoides, cada unidad del conjunto de datos se asigna a las unidades medoides más cercanas. El algoritmo sugerido por Kaufman y Rousseeuw (1990) para el método de clustering por c-medoides se desarrolla en dos fases:

Fase 1 (*CONSTRUCCIÓN*): Esta fase selecciona secuencialmente c unidades "centralmente localizadas" para ser utilizadas como medoides iniciales.

Fase 2 (*INTERCAMBIO*): Si la función objetivo puede reducirse intercambiando una unidad seleccionada con una no seleccionada, entonces se realiza el intercambio. Esto se repite hasta que la función objetivo ya no pueda ser disminuida. Luego, considerando un conjunto de I unidades representado por $\mathbf{X}$ (conjunto de las observaciones) y un subconjunto de $\mathbf{X}$ con C unidades representado por $\tilde{\mathbf{X}}$ (conjunto de los medoides), donde $C \ll I$, podemos formalizar el modelo de la siguiente manera:

$$\text{mín} : \sum_{i=1}^{I} \sum_{c=1}^{C} u_{ic}\, \tilde{d}_{ic}^2 = \sum_{i=1}^{I} \sum_{c=1}^{C} u_{ic}\, \|\mathbf{x}_i - \tilde{\mathbf{x}}_c\|^2, \tag{2.16}$$

$$\sum_{c=1}^{C} u_{ic} = 1, \quad u_{ic} \geq 0, \quad u_{ic} \in \{0, 1\} \tag{2.17}$$

donde u_{ic} indica el grado de pertenencia de la unidad i-ésima al cluster c-ésimo; $u_{ic} \in \{0, 1\}$, es decir, $u_{ic} = 1$ cuando la unidad i-ésima pertenece al cluster c-ésimo; $u_{ic} = 0$ en caso contrario; $\tilde{d}_{ic}^2 = \|\mathbf{x}_i - \tilde{\mathbf{x}}_c\|^2$ indica la distancia euclidiana al cuadrado entre el objeto i-ésimo y el medoide del clúster c-ésimo.

Algunos criterios útiles de validez para determinar el número de clusters son los siguientes:

Criterio de Calinski y Harabasz

Calinski y Harabasz (1974) sugieren tomar el valor de g, el número de clústeres, el cual corresponde al valor máximo de CH_C:

$$CH_C = \frac{\text{trace}(\mathbf{B})}{(C-1)} : \frac{\text{trace}(\mathbf{W})}{(I-C)}.$$

donde $\mathbf{B}$ es la matriz de dispersión entre grupos y $\mathbf{W}$ es la matriz de dispersión dentro de los grupos. La evaluación de este criterio en un número dado de grupos, C, requiere conocer la pertenencia a los grupos para determinar las matrices $\mathbf{B}$ y $\mathbf{W}$. En general, el número de grupos elegido depende del método de clúster utilizado.

Criterio de la silueta

Este criterio fue propuesto por Rousseeuw (1987). Considere una unidad $i \in (1, \ldots, I)$ perteneciente al cluster $p \in (1, \ldots, C)$. Por ejemplo, mediante un algoritmo de clustering *c-Medias*, esto significa que la unidad i-ésima está más cerca del centroide del cluster p-ésimo que de cualquier otro centroide.

Sea la distancia promedio (euclidiana al cuadrado) de la unidad i-ésima a todas las demás unidades que pertenecen al clúster p denotada por a_{ip}. Asimismo, sea la distancia promedio de esta unidad a todas las unidades que pertenecen a otro clúster q, $q \neq p$, llamada d_{iq}.

Finalmente, sea b_{ip} el mínimo d_{iq} calculado sobre $q = 1, \ldots, C,\ q \neq p$, lo cual representa la disimilitud de la unidad i-ésima con respecto a su cluster vecino más cercano.

Entonces, la silueta del objeto i-ésimo se define de la siguiente manera:

$$S_i = \frac{b_{ip} - a_{ip}}{\text{máx}\{a_{ip},\, b_{ip}\}} \tag{2.18}$$

donde el denominador es un término de normalización. Mientras mayor sea el valor de S_i, mejor es la asignación de la unidad i-ésima al cluster c-ésimo. La silueta, definida como el promedio de S_i para $i = 1, \ldots, I$, es:

$$SIL = \frac{1}{I} \sum_{i=1}^{I} S_i \tag{2.19}$$

La mejor partición se logra cuando la silueta se maximiza, lo cual implica minimizar la distancia intra-cluster (a_{ip}) mientras se maximiza la distancia inter-cluster (b_{ip}).

2.3.5. Método de K-means para series de tiempo.

El código del ejemplo se encuentra en GitHub con el nombre:
"07_Unsupervised_Clusteing_Time_Series" en GitHub.
Para la recolección de datos se usan:
"03_Ejemplo_Conexion_ServicioWeb" y "04_Generando_Datos_PML" en GitHub.

Bibliografía

[Cha20] Mark Chang. *Artificial Intelligence for Drug Development, Precision Medicine, and Healthcare*. Estados Unidos: CRC Press Taylor & Francis Group, 2020.

[Gre12] William H. Greene. *Econometric Analysis*. Mexico City: Prentice Hall, 2012.

[Hai+06] Joseph F. Hair et al. *Multivariate Data Analysis*. Prentice Hall, 2006.

[HTF17] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning. Data Mining, Inference, and Prediction*. LLC: Springer, 2017.

[LM12] Richard J. Larsen y Morris L. Marx. *An Introduction to Mathematical Statistics and its Applications*. Estados Unidos: Prentice Hall, 2012.

Apéndice A

Algunos teoremas y resultados relevantes

A.1. Convergencia